

Data Analyst Portfolio

김 새 한

비즈니스 문제를 데이터로 구조화하고, 액션 가능한
인사이트를 만드는 Data Analyst



togks7@naver.com



010-5611-0502



Git Hub

<https://github.com/kim-nyangnyang>

#책임감

#팀워크

#데이터_기반_사고



About Me

숫자 뒤의 의미를 읽는 데이터 분석가

통계적 분석 능력과 심리학적 통찰을 결합해,
단순한 수치 해석을 넘어 비즈니스적 전략과
사용자중심의 실질적인 가치를 제공합니다.

Academic Background



Main Major
통계학과 (Statistics)



Double Major
심리학과 (Psychology)



이화여자대학교 (2019.03 - 2023.02)

Interests: 예지정비 고객행동분석 의료데이터

★ Core Strengths



데이터 중심 사고
객관적 근거 기반 의사결정



책임감
끝까지 완수하는 집요함



팀워크
시너지를 창출하는 협업



커뮤니케이션
복잡한 분석의 직관적 전달



창의적 해결
새로운 관점의 접근



긍정적 태도
어려움 속 기회 발견



Value Proposition Workflow



문제 정의



데이터
수집/정제



분석 &
모델링



인사이트
도출



비즈니스
임팩트

“ 데이터 수집부터 비즈니스 의사결정까지 End-to-End로 수행합니다 ”

Resume

학력 & 경력

통계학&심리학 융합적 학문 배경과

장교 복무를 통한 리더십과 팀워크, 실무
중심의 데이터 분석 역량을 쌓아왔습니다.



Total Experience
2년 4개월



Education Level
학사 (복수전공)

2026.04 ~

국립중앙의료원 데이터기반 정책연구팀

- 의료취약지 모니터링 연구를 위한 주소 데이터 정제 및 API 기반 이동시간 산출
- 데이터 전처리 및 수집과정 자동화
- 바이트코딩을 통한 HTML 대시보드 제작

경력

2025.11 - 2026.04

멀티캠퍼스 (MultiCampus)

데이터 분석 과정 수료

Python/SQL 기반의 데이터 전처리, 시각화, 머신러닝 모델링 실무 교육 이수
다양한 팀 프로젝트를 통해 실무적 데이터 분석 프로세스 전반 경험

교육

2023.03 - 2025.06

대한민국 육군 (ROK Army)

장교 (중위 전역)

조직 관리: 30명 이상의 부대원 관리 및 상담, 인사 행정 업무 총괄
리더십: 부대 일정 조율, 리스크 관리, 상하급자 간 소통 및 협업 주도

경력

2019.03 - 2023.02

이화여자대학교

통계학과 / 심리학과 (복수전공)

통계적 방법론과 인간 행동에 대한 이해 함양. 데이터 기반의 가설 검증과 실험 설계 능력 습득

학력

Capabilities

기술 스택 & 자격증

데이터 수집부터 모델링, 시각화까지 분석 파이프라인 전과정을 수행할 수 있는 역량을 갖추었습니다.



Analysis

분석 및 개발 환경

- **Python:** pandas, numpy, scikit-learn, LightGBM, XGBoost, SHAP
- **SQL:** 데이터 추출, Join, 집계, 지표 산출, 데이터 정합성 검증
- **Statistics:** 가설 검정, ANOVA, VIF, 모델 평가 지표 해석



Data Handling

핵심 라이브러리

- API 호출, Geocoding, JSON Parsing, CSV 자동 전처리, SQLite
- ArcGIS



Visualization & Reporting

시각화 및 문서화

- **Tableau:** 대시보드 설계, 필터/인터랙션 구성, 분석 결과 리포팅
- **HTML/CSS:** 인터랙티브 분석 결과 페이지 제작
- **Streamlit:** 사용자 입력 기반 분석 서비스 구현



Certificates & Languages

자격 및 어학 역량

Certifications



빅데이터분석기사

한국데이터산업진흥원



SQLD

한국데이터산업진흥원



임상심리사 2급

산업인력공단

Languages

New TEPS

401

TOEIC

750

OPic

IM2

Team Project

고객 행동 데이터 기반 CRM · 이탈 관리 플랫폼

소규모 사업자를 위한
데이터 기반 CRM 및
마케팅 자동화 솔루션

📅 2026.02 - 진행중

👥 팀 프로젝트 (Role: 조장, 개발 리드)

Domain

Retail / CRM / Pet Care



프로젝트 목표

데이터 활용에 어려움을 겪는 **소상공인**을 위해, 간단한 정보
입력만으로 고객 이탈을 방지하고 매출을 증대하는 전략도출
CRM 플랫폼을 구축합니다.



데이터셋

Retail Transaction Data

- 고객 구매 이력 및 행동 로그 데이터
- 국내 시장상황에 맞춰 데이터 가공

사용자 파일 업로드(.csv) 기반 동적 분석

- SQLite를 활용한 로컬 데이터 관리



수행 역할

- 고객 구매 로그 기반 RFM 지표&카테고리별 재구매 주기 설계
- Rolling Window 시점별 학습 데이터 생성& 이탈 Labeling
- LightGBM 기반 이탈 예측 모델링 & 성능 평가
- 고객 세그먼트, Risk Score, 마케팅 액션 추천 기능 대시보드



기술 스택

Python

Streamlit

SQLite

pandas

scikit-learn

RFM Analysis



핵심 가치 (Value Proposition)

데이터 분석 비전문가도 직관적인 **대시보드**와 **자동화된 위험 점수(Risk Score)**를 통해 즉각적인
마케팅 실행과 고객 관리가 가능하도록 지원합니다.

Personal Project

01

항공기 엔진 고장 예측 & 예지정비

다변량 센서 데이터를 활용한
머신러닝 기반 잔여수명(RUL) 예측 및
비용기반 예지정비 의사결정 시스템

📅 2026.03

👤 개인 프로젝트 (기획/분석/모델링/인사이트)



Domain
Aerospace / Defense



프로젝트 목표

엔진 센서 데이터를 분석하여 **잔여 수명(RUL)**을 예측하고,
이를 바탕으로 **최적의 정비 시점**을 도출하여 운영 안정성
확보 및 정비 비용을 절감합니다.



데이터셋

NASA CMAPSS (FD001)

- 100개의 터보팬 엔진 시뮬레이션 데이터
- 21개의 센서 변수 (온도, 압력, 속도 등)
- 고장 시점까지의 Run-to-Failure 데이터



수행 역할

- **End-to-End 수행:** 문제 정의부터 데이터 전처리, 모델링,
비즈니스 의사결정 제안까지 전 과정 수행



기술 스택

Python Google Colab pandas scikit-learn
XGBoost RandomForest Matplotlib



핵심 가치 (Key Value)

기존 사후 대응 방식 대비 **유지보수 비용 절감** 및 돌발 고장으로 인한 **다운타임(Downtime) 최소화**를
실현하는 예지정비(Predictive Maintenance) 모델 구축

Personal Project

01

항공기 엔진 고장 예측 & 예지정비

다변량 센서 데이터를 활용한
머신러닝 기반 잔여수명(RUL) 예측 및
비용기반 예지정비 의사결정 시스템

📅 2026.03

👤 개인 프로젝트 (기획/분석/모델링/인사이트)



Domain
Aerospace / Defense



프로젝트 목표

엔진 센서 데이터를 분석하여 **잔여 수명(RUL)**을 예측하고,
이를 바탕으로 **최적의 정비 시점**을 도출하여 운영 안정성
확보 및 정비 비용을 절감합니다.



데이터셋

NASA CMAPSS (FD001)

- 100개의 터보팬 엔진 시뮬레이션 데이터
- 21개의 센서 변수 (온도, 압력, 속도 등)
- 고장 시점까지의 Run-to-Failure 데이터



수행 역할

- **End-to-End 수행:** 문제 정의부터 데이터 전처리, 모델링,
비즈니스 의사결정 제안까지 전 과정 수행



기술 스택

Python Google Colab pandas scikit-learn
XGBoost RandomForest Matplotlib




핵심 가치 (Key Value)

기존 사후 대응 방식 대비 **유지보수 비용 절감** 및 돌발 고장으로 인한 **다운타임(Downtime) 최소화**를
실현하는 예지정비(Predictive Maintenance) 모델 구축

데이터 분석 & Feature Engineering

Engine Unit: 100 | Sensor: 21 Types

EDA: 엔진 수명 분포



센서 그룹화 전략

핵심 변수 (Monotonic)

RUL과 강한 상관관계, 명확한 단조 추세
S2, S3, S4, S7, S8, S11, S12, S13, S15, S17, S20, S21

Keep

제거 변수 (Constant)

값의 변화가 없어 정보량 없음 (Variance=0)
S1, S5, S6, S10, S16, S18, S19

Drop

Feature Engineering 기법



Smoothing

이동평균 (MA)
Window=5



Volatility

롤링 표준편차
이상 징후 포착



Lag Features

시차 변수
Lag(t-1, t-3)




Difference

변화량 계산
급격한 열화 감지

성능 개선 효과 (RMSE)

파생변수 추가 시 Baseline 대비 예측 오차 감소



Final Feature Set

Cycle + 2 Settings + 14 Sensors + Derived Features

Selected

* R^2 Score: 0.853 (Random Forest with FE)

모델링 & 성능 평가

Final Model: Random Forest Regressor

검증 전략 (Validation Strategy)

GroupKFold Cross Validation

동일한 엔진의 시계열 데이터가 Train/Validation 셋에 분할되어 들어가는 **Data Leakage**를 방지하기 위해 Engine_id 기준으로 그룹을 분할하여 검증.



모델 최적화 (Optimization)

RandomizedSearchCV를 통한 하이퍼파라미터 튜닝

n_estimators: 100 ~ 500

max_depth: 10 ~ 30 (Overfitting 방지)

min_samples_split: Leaf node 조건 탐색

최종 모델 선정

Model	RMSE	R ² Score	비고
Random Forest	16.83	0.823	최종 선정
XGBoost	17.42	0.811	과적합 경향
Baseline	22.15	0.745	단순 회귀

Test Performance

0.823

R² Score

설명력 82.3%

16.83

RMSE

Cycles (오차)


11.20

MAE

Cycles (절대오차)

★ Feature Importance (Top 7)

Gini Impurity 기준



💡 Insight

이동평균(MA) 파생변수들이 상위권을 차지하며, 특히 **Sensor 11**과 **Sensor 4**의 추세정보가 RUL 예측에 결정적인 역할을 함.

Business Impact

성과 분석 & 의사결정 체계

Decision Support System

⚠️ 고장 위험도 평가

예측된 RUL 기반 3단계 위험 등급 및 현상 알림

● High Risk

즉각적인 가동 중단 및 긴급 정비

$$RUL \leq 0.5C$$

$$P \geq 0.7$$

● Medium Risk

정비 일정 수립 및 부품 확보

$$RUL \leq C$$

$$P \geq 0.3$$


● Low Risk

정상 운용 및 주기적 모니터링

$$RUL > C$$

$$P < 0.3$$


🔍 정비 의사결정 흐름도



❗ Policy 오탐(False Alarm) 비용보다 미탐(Missed Detection) 비용이 큰 특성 반영

💰 비용 절감 효과

79.2%
Cost Reduction



ReactivePredictive



Project Conclusion

데이터 기반 예지정비 도입으로 운영 효율성 4.8배 증대 예상


Total Savings
56,500 만원/ unit

Reliability
High

데이터 분석 & Feature Engineering

Engine Unit: 100 | Sensor: 21 Types

EDA: 엔진 수명 분포



센서 그룹화 전략

핵심 변수 (Monotonic)

RUL과 강한 상관관계, 명확한 단조 추세
S2, S3, S4, S7, S8, S11, S12, S13, S15, S17, S20, S21

Keep

제거 변수 (Constant)

값의 변화가 없어 정보량 없음 (Variance=0)
S1, S5, S6, S10, S16, S18, S19

Drop

Feature Engineering 기법



Smoothing

이동평균 (MA)
Window=5



Volatility

롤링 표준편차
이상 징후 포착



Lag Features

시차 변수
Lag(t-1, t-3)




Difference

변화량 계산
급격한 열화 감지

성능 개선 효과 (RMSE)

파생변수 추가 시 Baseline 대비 예측 오차 감소



Final Feature Set

Cycle + 2 Settings + 14 Sensors + Derived Features

Selected

* R² Score: 0.853 (Random Forest with FE)

모델링 & 성능 평가

Final Model: Random Forest Regressor

검증 전략 (Validation Strategy)

GroupKFold Cross Validation

동일한 엔진의 시계열 데이터가 Train/Validation 셋에 분할되어 들어가는 **Data Leakage**를 방지하기 위해 Engine_id 기준으로 그룹을 분할하여 검증.



모델 최적화 (Optimization)

RandomizedSearchCV를 통한 하이퍼파라미터 튜닝

n_estimators: 100 ~ 500

max_depth: 10 ~ 30 (Overfitting 방지)

min_samples_split: Leaf node 조건 탐색

최종 모델 선정

Model	RMSE	R ² Score	비고
 Random Forest	16.83	0.823	최종 선정
XGBoost	17.42	0.811	과적합 경향
Baseline	22.15	0.745	단순 회귀

Test Performance

0.823

R² Score

설명력 82.3%

16.83

RMSE

Cycles (오차)


11.20

MAE

Cycles (절대오차)

★ Feature Importance (Top 7)

Gini Impurity 기준



💡 Insight

이동평균(MA) 파생변수들이 상위권을 차지하며, 특히 **Sensor 11**과 **Sensor 4**의 추세정보가 RUL 예측에 결정적인 역할을 함.


Business Impact

성과 분석 & 의사결정 체계


Decision Support System

⚠️ 고장 위험도 평가

예측된 RUL 기반 3단계 위험 등급 및 현상 알림




🔍 정비 의사결정 흐름도



Policy 오탐(False Alarm) 비용보다 미탐(Missed Detection) 비용이 큰 특성 반영

💰 비용 절감 효과

79.2%
Cost Reduction



ReactivePredictive



Project Conclusion

데이터 기반 예지정비 도입으로 운영 효율성 4.8배 증대 예상

Total Savings
56,500 만원/ unit

Reliability
High

데이터 분석 & RFM 세분화

5단계 기술 아키텍처 (Technical Architecture)

- 1 데이터 로드 & 전처리 (Data Load)**
사용자 업로드 CSV 로드, 결측치 처리, 날짜/숫자형 변환, 이상치 제거
- 2 RFM 분석 & 세그먼트 (Feature Eng.)**
고객별 Recency, Frequency, Monetary 계산 및 6개 등급 분류, 파생변수 생성
- 3 시계열 학습 데이터 생성 (Rolling Window)**
6개 시점(Snapshot) 기준 과거 데이터로 Feature 생성, 미래 데이터로 Label 생성
- 4 이탈 예측 모델링 (Modeling)**
LightGBM Classifier 학습, 이탈 확률(Probability) 예측, 성능 평가
- 5 운영 & 액션 (Deployment)**
Streamlit 대시보드 시각화, Risk Score 산출, 마케팅 액션 자동 추천

RFM 분석 및 세그먼트 분류

RFM 정의 (Feature Engineering)

Recency (R)

마지막 구매 경과일

Frequency (F)

누적 주문 빈도

Monetary (M)

누적 매출 합계

6개 고객 세그먼트 분류 규칙 (Rule-based)

VVIP 🏆 $M \geq 80\%$
 $F \geq 80$
 $R \leq 20\%$ **VIP** $M \geq 60\%$
 $F \geq 60\%$ **고가치 감소형** $M \geq 60\text{th}$ (고매출)
 $R > 60\text{th}$ (최근 방문 포함)**휴면형** $R > 80\%$
(오랫동안 방문 없음)**활발한 일반 고객** $F \geq 50\%$
(평균 이상 방문)**관심필요 고객**나머지 모든 경우
(이탈 위험 높음)


데이터 분석 & RFM 세분화

💡 도메인 지식 활용: 카테고리별 재구매주기

Category	평균 재구매주기 (Median)	Churn 가중치 (Multiplier)
 Food (사료/간식)	21일	2.2배 (엄격)
 Disposables (배변패드)	25일	2.2배 (엄격)
 Grooming (미용)	27일	2.5
 Supplements (영양제)	35일	2.8
 Electronics (가전)	46일	3.0
 Cleaning Supplies	50일	3.0

🕒 Rolling Window 학습 데이터 생성

시간의 흐름에 따른 고객 변화 포착 (Time-Series Split)



30일 간격으로 6개 스냅샷 생성 → 과거 1년치 데이터 학습

📊 이탈(Churn) 레이블 생성 공식

이탈 판단 기준일 (Label Window) 계산

$\text{MAX}(\text{개인 평균 구매주기} \times \text{가중치}, \text{카테고리별 주기} \times \text{가중치})$

신규 고객(3개월 미만) 기준 완화

$\text{label_window} \times 1.5$

최종 이탈 여부 (Binary Classification Target)

$\text{Label Window} < \text{다음 구매 or 이후 구매 없음}$
→ 이탈(Churn = 1)

☰ 입력 변수 (13 Features)

 Frequency / Monetary

 Active Months

 AOV (객단가)

 Cycle Std (구매주기 편차)

 Food/Snack Ratio

 Disposable Ratio

 Grooming Ratio

 Final_Segment (One-hot)

모델링 & Risk Scoring

Target: Churn Prediction & Customer Segmentation

🎯 문제 정의 및 모델링 (Dual Modeling)

Classification (분류)
이탈/재구매 예측
LGBM Classifier

Regression (회귀)
고객가치(CLV) 예측
Regressor

📈 Risk Score 산출 및 등급화

이탈 예측 확률(Probability)을 0~100점 척도의 **Risk Score**로 변환하여 직관적인 지표 생성

High (80+)

Medium (50~79)

Low (<50)

💡 캠페인 물 & 추천 전략

Feature Importance 기반 물: 이탈 영향도가 높은 변수를 트리거로 자동 알림 설정

맞춤형 오퍼: 고위험군에게 할인 쿠폰, 충성고객군에게 신상품 알림 매칭

우선순위 큐 (Priority Queue): 일별 관리 대상 고객 리스트 생성하여 제공

📊 Model Performance

* 불균형 데이터셋 특성을 고려하여 PR-AUC 및 Recall 중점 평가

ROC-AUC

0.70

PR-AUC

0.78

Recall

0.77

📊 이탈 예측 주요 변수 (Top 5)

SHAP Value 기준

Recency (경과일)

Total Spend (총액)

Frequency (빈도)

Avg Basket (객단가)

Cancel Rate (취소율)

💡 **Insight** '마지막 구매 경과일(Recency)'이 이탈 예측에 압도적인 영향을 미침.
구매 주기가 길어지는 시점을 포착하는 것이 핵심.

Platform overview

데이터입력 & 플랫폼 사용설명

Target: Churn Prediction & Customer Segmentation



회원가입 & 로그인

00

분석데이터를 저장하고 이전 분석과 비교할 수 있습니다.



데이터 업로드 & 자동 전처리

01

CSV 파일을 드래그앤드롭으로 업로드하면 결측치를 보정합니다.
복잡한 전처리 과정 없이 즉시 분석 가능한 상태로 최적화됩니다.

CSV Support

Auto-Cleaning



지능형 컬럼 매핑 (Smart Mapping)

02

서로 다른 포맷의 데이터라도 '고객ID', '거래일시', '주문번호' 등 필수
분석 컬럼을 자동으로 인식하여 매핑합니다.
필요한 경우 수동으로 지정할 수 있습니다.

Auto-Detect


Flexible Schema



샘플 데이터 실험실

03

데이터가 없는 사용자를 위해 표준화된 샘플 데이터를 제공합니다.
다운로드하여 플랫폼의 기능을 체험하고 학습할 수 있습니다.



AI 기반 분석 & 인사이트



이탈률 예측 (Churn)

머신러닝 모델이 고객 행동 패턴을 학습하여 개별 고객의 이탈 확률을 스코어링하고, 대응합니다.



카테고리 & 세그먼트 분석

RFM분석을 통해 고객을 그룹화하여 관리합니다. 반려동물 용품은 정기구매가 잦아, 카테고리별 재구매주기를 고려해 관리합니다.




재고 예측 & 비교분석

카테고리별 매출 기여도와 성장세를 시계열로 분석하고, 향후 수요를 예측하여 적정 재고 수준을 제안합니다.



인사이트 도출

분석결과를 기반으로 세그먼트별, 고객별 쿠폰 지급, 알림 메시지 전송 등의 전략을 제시합니다.



국립중앙의료원

01

의료취약지 모니터링연구

의료취약지 모니터링을 위한
API 기반 이동시간 지표 개선

Domain
Medical / Traffic



문제정의

기존 도로망 기반 이동시간은 시간대별 교통량과 실제 도로 상황을 충분히 반영하지 못해, 의료 접근성 평가 결과가 현실과 다를 가능성이 있었습니다.

이에 실제 교통 데이터를 반영하는 API 기반 소요시간을 산출하고, 기존 도로망 지표와 비교하여 연구 적용 가능성을 검증했습니다.



수행 역할

- 비정형 주소 데이터 정규식 기반 정제
- Kakao/VWorld API Fallback 구조&& JSON 캐싱
- 도로망 평균시간, API 기반 시간대별 소요시간 비교
- 지역·기관·종별 필터링 HTML 대시보드 제작



Idea

실제 교통 빅데이터를 통해 이동시간을 예측하는 api의 이동시간이 더 현실과 부합하며, 시간대별 이동시간을 도출해 민감도 분석이 가능하다



기술 스택

Python

Geocoding

api



핵심 가치 (Key Value)

새로운 방식의 도입 및 연구의 질 개선
재사용 가능한 코드 설계 및 데이터 전처리

데이터 분석 & Feature Engineering

API 선택

다양한 후보군 탐색 및 특징 비교

- 비용, 정확도, 시간 지정 가능여부, 이동수단 등 다양한 요소를 비교
- 연구 활용 가능성을 고려한 선택

주소데이터 전처리 & API 호출

주소데이터 전처리

비정형 주소 텍스트 : 수만건의 주소 데이터에 층수·특수기호·괄호 혼재
→ 좌표변환실패 · API 호출 시 대량변환 실패 및 호출한도 초과

정규식 클렌징&다중API Fallback

4단계정제

괄호→coma→층수→보조번호

Fallback

Kakao → VWorld → 키워드우회+ JSON 캐싱

```

1 # 1.1.1.1을 제외한 모든 API(Kakao, World)를 위한 모든 키워드
cleaned = clean_v3(addr, level=1)
result = geocode_kakao(cleaned)

if not result: # 모든 키워드와 World 키워드
    cleaned = clean_v3(addr, level=3)
    result = geocode_kakao(cleaned)

if not result: # 모든 API(Kakao, World)를 위한 모든 키워드
    cleaned = clean_v3(addr, level=2)
    result = geocode_world(cleaned)

if not result and name: # 1.1.1.1을 제외한 모든 키워드와 World 키워드
    keyword = "(%s|(%s, %s, %s, %s))" % (name,
    result = geocode_kakao_keyword(keyword)

```

```
def clean_v3(addr, level=1):
    """해킹포인트 11번 키워드와 스캔 텍스트를 가져옴"""
    addr = str(addr).strip()
    if level >= 1: # 1번 키워드와 스캔 텍스트를 가져옴
        addr = re.sub(r'\\s+([{}@])', '\\1', addr)
        level = 2 and 'in addr: ' + addr + '을(를) 가져옴'
        addr = addr.split(' ')[0]
    if level >= 3: # 3번 키워드와 스캔 텍스트를 가져옴
        addr = re.sub(r'\\s+([{}@])', '\\1', addr)
        level = 4 and 'in addr: ' + addr + '을(를) 가져옴'
    if level >= 4: # 4번 키워드와 스캔 텍스트를 가져옴 (162-1 ~ 162-2)
        addr = re.sub(r'\\s+([{}@])', '\\1', addr)
    return re.sub(r'\\s+', '', addr).strip()
```

결과 보고서 작성 및 시각화



Html : <https://kim-nyangnyang.github.io/portfolio/>

기존결과와 비교

기존연구에서 도출된 시간과 시간대별 api시간 비교

기존연구와의 정합성 여부 확인

다양한 시각화 자료를 통한 설득력 향상



지역별 차이 비교

지역별 결과 차이 시각화를 통한 원인 파악

첨두, 비첨두시간 별 결과차이 확인

연구 적용 가능성 파악

바이브코딩을 통한 반응형 html제작

Mini Project

당뇨병 진단 & Tableau dashboard

건강 검진 지표 데이터를 활용한
당뇨병 발병 위험도 예측 및
주요 발병 원인(Risk Factor) 분석

Domain

Healthcare / Medical



프로젝트 목표

건강 검진 데이터를 기반으로 당뇨병 유무를 분류하는 **예측 모델**을 개발하고, VIF 및 SHAP 분석을 통해 당뇨 발병에 영향을 미치는 주요 인자를 도출합니다.



데이터셋

Kaggle Diabetes Health Indicators

- 미 CDC의 BRFSS(행동 위험 요인 감시 시스템) 설문 데이터
- 고혈압, 콜레스테롤, BMI 등 주요 건강 지표 변수 포함



역할 및 기여 (조장)

- **프로젝트 리딩**: 일정 조율 및 역할 분담
- **분석/개발**: 머신러닝 모델링(LightGBM), 코드 취합 및 관리
- **시각화**: 통계 분석 결과 해석 및 Tableau 대시보드 제작



기술 스택

Python

LightGBM

Logistic Regression

Tableau

SMOTE

SHAP

핵심 분석 방법론 (Key Methodology)



VIF로 다중공선성을 제거하고 **Class Imbalance** 문제를 해결하여 모델의 신뢰성을 확보했으며, **LightGBM**을 활용해 기존 로지스틱 회귀 대비 예측 성능을 향상시켰습니다. 앙상블 기법을 활용해 예측의 **견고함(Robustness)**과 **일반화 성능**을 높이고 극대화 변동성을 감소시켜 결과적으로 예측성능을 향상시켰습니다.

모델링 결과 & 핵심 인사이트

Final Model: LightGBM

모델 성능 비교 (Model Comparison)

Model	AUC-ROC	Recall	비고
✓ LightGBM	0.72	0.72	최종 선정 (균형잡힌 성능)
Logistic Regression	0.69	0.59	재현율(Recall) 저조
Random Forest	0.68	0.61	과적합 경향, 속도효율 ↓

성능 최적화 전략

⚠ 클래스 불균형 해결

scale_pos_weight 파라미터를 적용하여 당뇨 환자에 대한 가중치 부여, 재현율(Recall) 대폭 개선.

⚠ 다중공선성(VIF) 제어

허리둘레비율(WHR) 등 VIF가 높은 변수를 제거하고 Effect Size 기반 핵심 변수 선별.

Final Evaluation

0.72

AUC-ROC

모델 변별력

0.72

Recall

환자 예측율 (중요)


0.65

Accuracy

전체 정확도

SHAP Feature Importance (Top 5)

SHAP value magnitude




💡 Insight 가속력(0.407)과 신체활동(0.401)이 가장 결정적인 요인으로 확인됩니다. 유전적 요인 외에도 생활습관(운동, 지질수치) 관리가 당뇨 예방에 중요함을 보여줍니다.

SHAP Analysis


Tableau를 활용한 대시보드

https://public.tableau.com/app/profile/.75493083/viz/diabetes_tableau/14



분석 시각화

데이터 분석 및 머신러닝 결과를 히트맵, 버블차트 등 다양한 시각화 도구를 활용해 직관적인 대시보드를 구축했습니다.



인사이트 도출

종합적인 분석결과 및 보호요인, 위험요인을 요약하고, 분석을 통해 도출할 수 있는 당뇨 예방 및 관리방법을 제시했습니다.